



Universidade  
Federal do  
Agreste de  
Pernambuco

## UNIVERSIDADE FEDERAL DO AGRESTE DE PERNAMBUCO

bacharelado em ciência da computação

estudo dirigido - Reconhecimento de Padrões 2026.1 - Prof. Dr. Luis Filipe

### 1 Objetivos de aprendizagem

- Escolher uma *task* do pacote `exercises`, disponível no projeto<sup>1</sup>, e identificar as variáveis que controlam seu funcionamento;
- Formular hipóteses sobre os efeitos provocados pela alteração de diferentes variáveis;
- Medir e comparar as diferentes configurações quanto à **métrica final de desempenho** (acurácia ou *silhouette score*) e ao **número de FLOPs**;
- Analisar o *trade-off* entre a qualidade dos resultados e o custo computacional;

### 2 Organização e acompanhamento

A atividade será realizada em individualmente, sob a forma de estudo dirigido. Cada aluno deverá desenvolver o projeto com autonomia, seguindo este roteiro e os materiais indicados pelo professor.

O acompanhamento ocorrerá predominantemente de forma assíncrona, por meio de interações realizadas no ambiente virtual da disciplina. Os estudantes poderão enviar dúvidas, apresentar resultados parciais e solicitar orientações sobre a modelagem, a implementação e a validação.

#### Passo 1 — Escolha da *task*

Escolha uma das atividades disponíveis no pacote `exercises` do projeto:

- **Classificação** (`python -m exercises.task_binary_classification`) — treinamento de uma MLP com arquitetura `Linear → ReLU → Linear` no conjunto de dados Adult. A métrica final corresponde à acurácia nos conjuntos de treinamento, validação e teste;
- **Aprendizado de embeddings** (`python -m exercises.task_learn_embedding`) — treinamento de um modelo Word2Vec utilizando o corpus da obra *Flatland*. A métrica final corresponde ao *silhouette score* calculado antes e depois do treinamento.

---

<sup>1</sup><https://github.com/luisfilipeap/BERT-cpu/>

## Passo 2 — Escolha da questão de investigação

Escolha uma das questões de investigação disponíveis no pacote `exercises`:

`q01_activations` Investiga a implementação e a comparação de diferentes funções de ativação. A questão central é: *uma função de ativação pode ser responsável pelo melhor desempenho global do sistema em determinada tarefa?*

`q02_rewrite_the_stars` Investiga a implementação de novas camadas neurais baseadas no operador estrela, como alternativa às camadas totalmente conectadas tradicionais. A questão central é: *a substituição de uma camada totalmente conectada por uma camada baseada no operador estrela pode melhorar o desempenho do modelo sem aumentar excessivamente seu custo computacional? Quais opções possíveis de novas camadas usando o operador estrela?*

### Fundamentação teórica:

1. Ma, X.; Dai, X.; Bai, Y.; Wang, Y.; Fu, Y. “Rewrite the Stars”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024, p. 5694–5703.

`q03_gated_linear_units` Investiga a implementação de camadas neurais que incorporam portões (*gates*) para controlar o fluxo de informação e filtrar as ativações produzidas pela rede. A questão central é: *o uso de portões permite que a rede selecione informações mais relevantes e alcance um melhor equilíbrio entre desempenho e custo computacional? De quantas formas diferentes os portões podem ser utilizados no neurônio/camada?*

### Fundamentação teórica:

1. Dauphin, Y. N.; Fan, A.; Auli, M.; Grangier, D. “Language Modeling with Gated Convolutional Networks”. In: *Proceedings of the 34th International Conference on Machine Learning*, PMLR, v. 70, 2017, p. 933–941.
2. Shazeer, N. “GLU Variants Improve Transformer”. 2020. O trabalho apresenta e discute variantes como ReGLU, GEGLU e SwiGLU.

`q04_learnable_activations` Investiga camadas nas quais a função de ativação não é definida previamente, mas aprendida durante o treinamento. A questão central é: *aprender uma combinação de funções de ativação pode produzir resultados melhores do que utilizar uma única função fixa, e qual é o custo computacional adicional dessa escolha?*

### Fundamentação teórica:

1. Wang, M.; Wang, J.; Xia, Y.; Shen, K.; Zhong, S. “More Expressive Feed-forward Layers: Part I. Token-Adaptive Mixing of Activations”. 2026.

## Passo 3 — Defina um protocolo experimental

Regra de ouro: **varie UMA variável por vez** e fixe `cpu.set_seed(0)` para que a diferença observada venha da variável em análise, e não do acaso. A task de classificação *já* imprime os FLOPs (por época e o total em GFLOP). Para a de embedding, meça um passo de treino envolvendo-o entre `cpu.reset_flops()` e `cpu.flop_count()`.

| Configuração | Variável | alte- | Taxa             | final | FLOPs    | Observações |
|--------------|----------|-------|------------------|-------|----------|-------------|
|              | rada     |       | (acc/silhouette) |       | (~GFLOP) |             |
| baseline     | —        |       |                  |       |          |             |

## Passo 4 — Análise do *trade-off*

Esboce um gráfico que represente a relação entre uma **métrica de desempenho** e o **número de FLOPs** para as configurações avaliadas em seus experimentos. Em seguida, responda:

- Qual configuração apresenta o melhor retorno por FLOP, isto é, o maior desempenho em relação ao custo computacional?
- A partir de qual configuração começam a ocorrer *retornos decrescentes*, de modo que o aumento do custo computacional deixa de produzir ganhos relevantes de desempenho?
- Qual variável provoca uma grande variação no número de FLOPs, mas produz pouca alteração no desempenho? Existe alguma variável que apresente o comportamento contrário?
- Caso houvesse um orçamento computacional fixo, expresso em FLOPs, qual configuração você escolheria? Justifique sua resposta com base nos resultados experimentais.

## 3 Entrega

A entrega deverá conter:

- link para vídeo, **de até 20 minutos**, com a apresentação do estudante;
- link para repositório github com README.md detalhado com instruções claras de instalação e replicação dos experimentos;
- dependências necessárias em arquivo requirements.txt;

## 4 Conteúdo obrigatório do vídeo de apresentação

A apresentação do aluno deverá apresentar:

1. o que foi delegado a ferramentas de IA generativa e como o código, as explicações ou as sugestões produzidas foram verificados, corrigidos e validados pelo estudante;
2. a tarefa de aprendizado de máquina escolhida, incluindo o conjunto de dados, as entradas, as saídas, o objetivo do treinamento e a métrica utilizada para avaliar o desempenho;
3. a configuração de referência (*baseline*) utilizada no experimento e os motivos de sua escolha;
4. a variável de interesse modificada em cada experimento e quais elementos foram mantidos constantes para garantir uma comparação controlada;
5. a formulação matemática ou computacional da modificações investigadas, explicando como ela altera o processamento realizado pela rede neural;
6. o funcionamento da arquitetura e do processo de treinamento, relacionando a implementação aos conceitos teóricos estudados na disciplina;
7. o protocolo experimental, incluindo o número de configurações, as repetições realizadas, as sementes aleatórias, e as métricas de desempenho escolhidas (especialmente para a tarefa *embedding*);
8. os resultados obtidos em cada configuração, apresentados por meio de tabelas, gráficos ou registros de treinamento;
9. a relação entre a métrica de desempenho e o número de FLOPs, identificando a configuração com melhor retorno computacional e os possíveis pontos de retornos decrescentes;
10. a comparação entre as hipóteses iniciais e os resultados observados, indicando quais hipóteses foram sustentadas, refutadas ou permaneceram inconclusivas;
11. as dificuldades encontradas durante a implementação, incluindo erros, instabilidades, resultados inesperados e alterações realizadas ao longo do desenvolvimento;
12. os procedimentos necessários para reproduzir o experimento, incluindo dependências, comandos de execução, configurações utilizadas e organização dos arquivos.

**Não será suficiente apenas executar o código ou apresentar as métricas finais. O estudante deverá demonstrar que compreende a modificação implementada, seus fundamentos teóricos, seus efeitos sobre o modelo e as conclusões que podem ser sustentadas pelos resultados experimentais.**

Tabela 1: Bonificação conforme o escopo da investigação experimental.

| <b>Escopo do estudo</b>                                    | <b>Bonificação na 1ª VA</b> |
|------------------------------------------------------------|-----------------------------|
| Estudo <b>aprofundado</b> de uma variável do experimento   | <b>ATÉ 0,5 ponto</b>        |
| Estudo <b>aprofundado</b> de duas variáveis do experimento | <b>ATÉ 1,0 ponto</b>        |
| Estudo <b>aprofundado</b> de três variáveis do experimento | <b>ATÉ 1,5 ponto</b>        |

## 5 Pontuação e prazo

A bonificação atribuída ao estudo dirigido dependerá do número de variáveis investigadas e da profundidade da análise experimental, conforme apresentado na Tabela 1.

**Data-limite para entrega: 24 de julho de 2026.**

Forma de envio: Ambiente Virtual Classroom